

教育是否提高中国成年人的收入？ 基于 CFPS 2022 的数据审计、双重稳健估计与弱工 具变量诊断

实证论文

2026 年 6 月 25 日

摘要

本文使用 CFPS 2022 微观数据重新考察教育是否提高中国成年人的收入。相较于传统明瑟方程，本文做了三方面改进。第一，加入完整的数据质量检查，报告样本筛选、缺失情况、异常值处理和共同支撑。第二，将核心问题从“受教育年限与收入是否相关”推进到“大专及以上学历教育是否提高工资收入”，并使用交叉拟合的增强逆概率加权 (AIPW) 估计平均处理效应。第三，检验而不是直接假定 1999 年高等教育扩招可以作为工具变量识别策略。最终分析样本为 4,699 名劳动年龄成年人。OLS 结果显示，受教育年限每增加一年，工资收入约高 8.8%；大专及以上学历教育对应约 0.74 个对数点的工资优势。首选 AIPW 估计为 0.710 个对数点，稳健性估计范围为 0.669–0.773。平衡性诊断显示，权重显著降低了年龄、性别、户口、城乡、婚姻和医保等协变量差异。然而，扩招工具变量在较窄出生队列窗口中的第一阶段很弱，因此本文只将其作为诊断结果，而不将其包装为主要因果证据。总体而言，本文支持教育与收入之间存在显著正向关系，并提供了比简单 OLS 更扎实的选择性可观测条件下的处理效应估计。

关键词：教育；收入；CFPS；双重稳健估计；因果推断；高等教育扩招

1 引言

教育是解释劳动市场收入差异的重要因素。人力资本理论认为，教育能够通过提升技能、生产率和职业匹配质量来增加收入 [Becker, 1964, Mincer, 1974]。但是，教育并非随机分配，家庭背景、能力、地区机会和制度条件可能同时影响教育和收入，因此简单 OLS 往往只能解释为条件相关关系 [Card, 1999, Heckman et al., 2008]。

本文此前版本主要回答“教育与收入是否显著正相关”。这个问题有意义，但创新性和因果推断不足。新版论文将研究设计改为三层结构：第一，先做数据审计，说明样本如何

从原始数据进入最终回归；第二，以“大专及以上学历”为处理变量，使用双重稳健 AIPW 方法估计平均处理效应 [Hirano et al., 2003, Bang and Robins, 2005]；第三，尝试利用 1999 年高等教育扩招作为政策暴露，但根据第一阶段强度判断其是否可作为主识别策略。

因此，本文的创新并不是声称已经获得完美因果识别，而是在可用数据条件下更诚实、更扎实地推进识别：OLS 作为基准，AIPW 作为主要因果推断框架，扩招工具变量作为经过检验的辅助诊断。

2 文献与识别思路

本文的起点是明瑟收入方程 [Mincer, 1974]。大量研究发现教育与收入正相关，但也强调 OLS 可能受到不可观测能力和家庭背景影响 [Card, 1999]。在中国语境下，Zhang et al. [2005] 发现市场化改革时期城市教育回报上升，Asadullah and Xiao [2020] 和 Ma and Iwasaki [2021] 进一步说明教育回报会随时期、性别、户口、地区和部门而变化。

高等教育扩招文献为因果识别提供了重要启发。Huang et al. [2022] 利用高等教育扩招考察教育回报及户口差异。本文借鉴这一政策思路，但不直接假定其在 CFPS 2022 横截面中有效，而是先检验 1981 年前后出生队列是否存在足够强的教育跳跃。根据回归断点设计的实践要求 [Imbens and Lemieux, 2008, Lee and Lemieux, 2010]，如果局部第一阶段很弱，就不应将其作为主因果证据。

本文主要使用选择性可观测条件下的 AIPW 估计。AIPW 同时结合结果模型和倾向得分模型；在条件可忽略性成立时，只要其中一个模型设定正确，估计量仍可保持一致 [Bang and Robins, 2005]。由于该假设无法直接检验，本文同时报告倾向得分重叠和平衡性改善情况。

3 数据与数据检查

本文使用 CFPS 2022 数据 [Xie and Lu, 2015, Institute of Social Science Survey, Peking University, 2022]。原始数据包含 9,806 个观测值。样本处理包括保留 18–64 岁成年人、要求工资收入可得、并要求核心变量完整。表 1 展示样本筛选过程。

表 1: 样本构造过程

步骤	样本量	规则
CFPS 2022 原始数据	9,806	
保留 18–64 岁成年人	7,975	年龄限制
要求工资变量非缺失	4,718	因变量可得
要求核心变量完整	4,699	最终分析样本

主要因变量为 $\ln(\text{wage} + 1)$ 。连续教育变量为受教育年限；因果估计中的处理变量为是否完成大专及以上学历教育。表 2 显示，工资变量缺失是样本减少的主要来源，而多数协变量缺失比例较低。工资的 99 分位数为 300,000 元，因此稳健性检验中加入工资缩尾口径。

表 2: 原始数据缺失情况检查

变量	缺失样本量	缺失比例
wage	4,934	50.32
educ	1	0.01
age__	0	0.00
gen	0	0.00
mar	261	2.66
rural	97	0.99
urban	79	0.81
health	139	1.42
inter	350	3.57
dw	408	4.16
asset	926	9.44

表 3: 描述性统计

变量	样本量	均值	标准差	最小值	中位数	最大值
年度工资收入	4,699	60594.132	68985.459	0.000	48000.000	1800000.000
$\ln(\text{工资} + 1)$	4,699	10.489	1.567	0.000	10.779	14.403
受教育年限	4,699	11.006	4.376	0.000	12.000	22.000
大专及以上学历	4,699	0.347	0.476	0.000	0.000	1.000
出生年份	4,699	1981.133	10.921	1958.000	1982.000	2004.000
年龄	4,699	40.867	10.921	18.000	40.000	64.000
男性	4,699	0.575	0.494	0.000	1.000	1.000
农业户口	4,699	0.795	0.404	0.000	1.000	1.000
城镇居住	4,667	0.637	0.481	0.000	1.000	1.000
是否上网	4,685	0.874	0.332	0.000	1.000	1.000
自评健康	4,673	3.215	1.045	1.000	3.000	5.000

表 4: 教育水平分布

教育类别	样本量	占比 (%)
文盲	243	5.17
小学	589	12.53
初中	1,463	31.13
高中	774	16.47
大专	702	14.94
本科	824	17.54
硕士	91	1.94
博士	13	0.28




图 1: 分析样本的教育构成




图 2: 不同教育水平的平均对数工资

4 实证策略

4.1 OLS 基准模型

基准模型为：

$$\ln(\text{wage}_i + 1) = \alpha + \beta E_i + \gamma X_i + \mu_p + \varepsilon_i, \quad (1)$$

其中 E_i 表示受教育年限或大专及以上学历教育， X_i 为控制变量， μ_p 为省份固定效应。所有回归均使用稳健标准误。OLS 用作基准结果，但不直接解释为严格因果效应。

4.2 双重稳健处理效应估计

本文的核心估计量是大专及以上学历教育的平均处理效应：

$$ATE = E[Y_i(1) - Y_i(0)]. \quad (2)$$

AIPW 个体得分为：

$$\hat{\tau}_i = \hat{m}_1(X_i) - \hat{m}_0(X_i) + \frac{D_i(Y_i - \hat{m}_1(X_i))}{\hat{e}(X_i)} - \frac{(1 - D_i)(Y_i - \hat{m}_0(X_i))}{1 - \hat{e}(X_i)}, \quad (3)$$

其中 D_i 表示是否完成大专及以上学历教育， $\hat{e}(X_i)$ 为倾向得分， $\hat{m}_d(X_i)$ 为处理状态 d 下的预测收入。本文使用五折交叉拟合，并同时报告线性模型和梯度提升模型。首选设定控制年龄、性别、户口、城乡、婚姻、医保和省份；扩展设定进一步加入健康、家庭规模、社会地位、是否上网和就业状态。

4.3 扩招工具变量诊断

1999 年中国高等教育扩招提供了一个潜在政策冲击。本文用出生年份减 1981 作为 running variable，因为 1981 年出生队列在 1999 年大约 18 岁。若该设计有效，1981 年及以后出生应在教育水平上出现局部跳跃。本文在多个对称出生队列窗口中报告第一阶段和 IV 估计，以判断这一识别策略是否足够强。

5 实证结果

5.1 OLS 基准结果

表 5 显示，OLS 结果方向稳定。基础设定中，受教育年限系数为 0.088；加入更多控制变量后为 0.083。以大专及以上学历作为处理变量时，基础设定系数为 0.738，扩展设定为 0.694。

表 5: OLS 基准估计

模型	系数	稳健标准误	样本量	R^2
年限: 基础控制	0.0882***	(0.0062)	4,699	0.158
年限: 扩展控制	0.0825***	(0.0065)	4,637	0.163
大专: 基础控制	0.7381***	(0.0502)	4,699	0.154
大专: 扩展控制	0.6935***	(0.0509)	4,637	0.162
工资缩尾	0.7291***	(0.0499)	4,699	0.152
正工资样本	0.6420***	(0.0300)	4,638	0.285

注：括号内为稳健标准误。基础控制变量包括年龄、年龄平方、性别、婚姻、农业户口、医保和省份固定效应；扩展控制变量进一步加入城乡、健康、家庭规模、是否上网和主观社会地位。
* $p < 0.10$, ** $p < 0.05$, *** $p < 0.01$ 。




图 3: 不同模型中的教育收入系数

5.2 双重稳健估计

表 6 报告 AIPW 结果。首选的 Core plus + GBM 估计为 0.710，标准误为 0.056。六组设定的估计范围为 0.669–0.773，说明结果并不依赖单一协变量组合或单一学习器。

表 6: 大专及以上学历教育的 AIPW 估计

协变量	学习器	ATE	标准误	95% CI	样本量	AUC
Core	Linear	0.7726***	(0.0551)	[0.6647, 0.8806]	4,699	0.814
Core	GBM	0.7206***	(0.0553)	[0.6123, 0.8289]	4,699	0.822
Core plus	Linear	0.7611***	(0.0583)	[0.6467, 0.8755]	4,699	0.816
Core plus	GBM	0.7103***	(0.0556)	[0.6014, 0.8193]	4,699	0.827
Extended	Linear	0.7088***	(0.0544)	[0.6022, 0.8154]	4,699	0.829
Extended	GBM	0.6690***	(0.0495)	[0.5720, 0.7660]	4,699	0.844

注：因变量为 $\ln(\text{wage} + 1)$ 。ATE 表示完成大专及以上学历教育的平均处理效应。Linear 使用逻辑回归/Ridge 结果模型；GBM 使用梯度提升模型。首选设定为 Core plus + GBM。

AIPW 的可信度取决于共同支撑和平衡性。图 4 显示处理组和对照组在较宽的倾向得分区间内存在重叠，但两端仍有少量样本。表 7 和图 5 显示，加权后核心协变量的标准化差异绝对值均降至 0.10 以下。




图 4: 倾向得分共同支撑

表 7: 加权前后的协变量平衡性

协变量	原始 SMD	加权 SMD
age__	-0.937	-0.072
gen	-0.214	0.033
rural	-0.525	-0.024
urban	0.642	0.033
mar	-0.286	-0.023
medsure_dum	0.079	-0.001




图 5: 加权前后的标准化均值差异

5.3 弱工具变量诊断

图 6 展示 1981 年 cutoff 附近出生队列的大专及以上比例和平均教育年限。表 8 显示，在 ± 5 到 ± 15 年的较窄窗口中，第一阶段 F 统计量远低于常用弱工具变量阈值。 ± 20 年窗口的第一阶段较强，但窗口过宽，已经难以解释为局部断点。因此，扩招 IV 不作为本文主要因果证据。




图 6: 高等教育扩招 cutoff 附近的出生队列模式

表 8: 高等教育扩招 IV 诊断

窗口	样本量	第一阶段	F 统计量	IV 估计	标准误
+/-5	1,280	-0.0743	0.03	0.5195	(3.2703)
+/-7	1,844	0.1961	0.29	0.4589	(0.9572)
+/-9	2,462	-0.0481	0.02	0.2091	(2.4996)
+/-12	3,277	0.1269	0.21	-0.7816	(2.0357)
+/-15	3,933	0.3977	2.54	-0.1531	(0.2721)
+/-20	4,596	1.2985	33.22	0.0414	(0.0633)

注：工具变量为是否出生于 1981 年及以后，并控制线性 running variable、交互项和省份固定效应。较窄窗口中的第一阶段较弱，因此 IV 结果不应被解释为主要因果证据。

5.4 异质性

表 9 和图 7 显示，女性样本中的教育系数高于男性，非农业户口样本中的教育系数高于农业户口样本。这与中国教育回报存在性别、户口、部门和地区差异的既有文献相一致 [Ma and Iwasaki, 2021, Li et al., 2025]。

表 9: 不同子样本中的教育系数

子样本	教育系数	稳健标准误	样本量	R^2
女性	0.1104***	(0.0094)	1,996	0.155
男性	0.0668***	(0.0069)	2,703	0.145
非农业户口	0.1482***	(0.0201)	962	0.144
农业户口	0.0771***	(0.0066)	3,737	0.128




图 7: 性别与户口子样本中的教育收入系数

6 讨论

新版实证相较于简单 OLS 有三点实质改进。第一，本文直接报告样本筛选和缺失情况，避免只展示最终回归样本。第二，本文将研究对象从“每增加一年教育”的相关关系扩展为“大专及以上学历教育”的处理效应，并使用双重稳健估计。第三，本文尝试政策型识别，但根据弱工具变量诊断保留谨慎解释，而不是为了创新而强行声称因果识别成功。

本文仍有局限。AIPW 依赖可观测变量调整，而当前数据文件缺少能力、父母教育、童年家庭资源和学校质量等重要变量。因此，首选估计应理解为选择性可观测条件下的双重稳健处理效应，而不是完全等同于随机实验或强工具变量估计。扩招 IV 的弱第一阶段也说明，仅凭当前横截面数据不宜做过强的政策因果结论。

7 结论

基于 CFPS 2022，本文发现教育与中国成年人收入之间存在显著正向关系。传统明瑟模型中，受教育年限每增加一年，工资收入约高 8.8%。更重要的是，AIPW 结果显示，在平衡可观测协变量后，大专及以上学历教育对应约 0.71 个对数点的工资收入优势。该结果在不同协变量口径和学习器下保持稳定，且加权后协变量平衡明显改善。本文因此提供了一份比单纯 OLS 更有创新性、实证更扎实、并明确做过数据检查的教育收入研究。

参考文献

- M. Niaz Asadullah and Saizi Xiao. The changing pattern of wage returns to education in post-reform china. *Structural Change and Economic Dynamics*, 53:137–148, 2020. doi: 10.1016/j.strueco.2020.01.010.
- Heejung Bang and James M. Robins. Doubly robust estimation in missing data and causal inference models. *Biometrics*, 61(4):962–973, 2005. doi: 10.1111/j.1541-0420.2005.00377.x.
- Gary S. Becker. *Human Capital: A Theoretical and Empirical Analysis, with Special Reference to Education*. National Bureau of Economic Research, New York, 1964. URL <https://www.nber.org/books-and-chapters/human-capital-theoretical-and-empirical-analysis-special-reference-education-first-edition>.
- David Card. The causal effect of education on earnings. In Orley C. Ashenfelter and David Card, editors, *Handbook of Labor Economics*, volume 3A, pages 1801–1863. Elsevier, 1999. doi: 10.1016/S1573-4463(99)03011-4.
- James J. Heckman, Lance J. Lochner, and Petra E. Todd. Earnings functions and rates of return. *Journal of Human Capital*, 2(1):1–31, 2008. doi: 10.1086/587037.
- Keisuke Hirano, Guido W. Imbens, and Geert Ridder. Efficient estimation of average treatment effects using the estimated propensity score. *Econometrica*, 71(4):1161–1189, 2003. doi: 10.1111/1468-0262.00442.
- Bin Huang, Massimiliano Tani, Yi Wei, and Yu Zhu. Returns to education in china: Evidence from the great higher education expansion. *China Economic Review*, 74:101804, 2022. doi: 10.1016/j.chieco.2022.101804.
- Guido W. Imbens and Thomas Lemieux. Regression discontinuity designs: A guide to practice. *Journal of Econometrics*, 142(2):615–635, 2008. doi: 10.1016/j.jeconom.2007.05.001.
- Institute of Social Science Survey, Peking University. China family panel studies 2022. Survey data, 2022. URL <https://www.issp.pku.edu.cn/cfps/>.
- David S. Lee and Thomas Lemieux. Regression discontinuity designs in economics. *Journal of Economic Literature*, 48(2):281–355, 2010. doi: 10.1257/jel.48.2.281.
- Mingming Li, Xinyun Hu, and Keyan Jin. The return on education and the gender wage gap in china: A sector perspective. *SAGE Open*, 2025. doi: 10.1177/21582440251327015.

- Xinxin Ma and Ichiro Iwasaki. Return to schooling in china: A large meta-analysis. *Education Economics*, 29(4):379–410, 2021. doi: 10.1080/09645292.2021.1900791.
- Jacob Mincer. *Schooling, Experience, and Earnings*. National Bureau of Economic Research, New York, 1974. URL <https://www.nber.org/books-and-chapters/schooling-experience-and-earnings>.
- Yu Xie and Ping Lu. The sampling design of the china family panel studies (cfps). *Chinese Journal of Sociology*, 1(4):471–484, 2015. doi: 10.1177/2057150X15614535.
- Junsen Zhang, Yaohui Zhao, Albert Park, and Xiaoqing Song. Economic returns to schooling in urban china, 1988 to 2001. *Journal of Comparative Economics*, 33(4):730–752, 2005. doi: 10.1016/j.jce.2005.05.008.