

教育是否提高中国成年人的收入？

基于 CFPS 2022 的数据审计、双重稳健估计与弱工具变量诊断

实证论文

2026 年 6 月 25 日

摘要

本文使用 CFPS 2022 微观数据考察教育与中国成年人收入之间的关系。与只估计明瑟方程的做法不同，本文先对样本筛选、变量缺失、工资极端值和倾向得分重叠情况进行检查，然后将“大专及以上学历教育”定义为处理变量，用交叉拟合的增强逆概率加权 (AIPW) 估计平均处理效应。本文还尝试把 1999 年高等教育扩招转化为出生队列层面的政策暴露，并报告其第一阶段强度，以判断该思路能否支撑工具变量解释。最终样本包含 4,699 名劳动年龄成年人。OLS 结果显示，受教育年限每增加一年，工资收入约高 8.8%；完成大专及以上学历教育对应约 0.74 个对数点的工资优势。首选 AIPW 估计为 0.710 个对数点，其他设定下的估计值位于 0.669–0.773 之间。加权后，年龄、性别、户口、城乡、婚姻和医保等核心协变量的标准化差异明显下降。扩招变量在较窄出生队列窗口中的第一阶段较弱，因此本文不把它作为主要因果证据。总体来看，教育与收入之间存在稳定的正向关系；在可观测变量得到较充分控制后，大专及以上学历教育仍对应较高的工资收入。

关键词：教育；收入；CFPS；双重稳健估计；因果推断；高等教育扩招

1 引言

教育是解释劳动市场收入差异的重要因素。人力资本理论认为，教育能够通过提升技能、生产率和职业匹配质量来增加收入 [Becker, 1964, Mincer, 1974]。但是，教育并非随机分配，家庭背景、能力、地区机会和制度条件可能同时影响教育和收入，因此简单 OLS 往往只能解释为条件相关关系 [Card, 1999, Heckman et al., 2008]。

单纯估计教育年限的 OLS 系数，很容易把论文停留在“教育和收入正相关”这一层。本文在保留明瑟方程作为基准的同时，把分析推进到两个更具体的问题：完成大专及以上学历教

育后，收入差异在平衡可观测特征后是否仍然存在；1999 年高等教育扩招能否在当前样本中形成足够强的外生教育冲击。前一个问题使用双重稳健 AIPW 方法处理 [Hirano et al., 2003, Bang and Robins, 2005]，后一个问题则通过出生队列窗口中的第一阶段检验来判断。

这种处理方式的目的，是把“相关性发现”和“因果解释”区分开来。OLS 结果用于展示教育收入梯度，AIPW 结果用于给出选择性可观测条件下的处理效应估计，扩招设计则作为一个被数据检验过的政策识别尝试。若第一阶段不支持，本文不继续给出过强的 IV 解释。

2 文献与识别思路

本文的起点是明瑟收入方程 [Mincer, 1974]。大量研究发现教育与收入正相关，但也强调 OLS 可能受到不可观测能力和家庭背景影响 [Card, 1999]。在中国语境下，Zhang et al. [2005] 发现市场化改革时期城市教育回报上升，Asadullah and Xiao [2020] 和 Ma and Iwasaki [2021] 进一步说明教育回报会随时期、性别、户口、地区和部门而变化。

高等教育扩招文献为因果识别提供了重要启发。Huang et al. [2022] 利用高等教育扩招考察教育回报及户口差异。本文借鉴这一政策思路，但不直接假定其在 CFPS 2022 横截面中有效，而是先检验 1981 年前后出生队列是否存在足够强的教育跳跃。根据回归断点设计的实践要求 [Imbens and Lemieux, 2008, Lee and Lemieux, 2010]，如果局部第一阶段很弱，就不应将其作为主因果证据。

本文主要使用选择性可观测条件下的 AIPW 估计。AIPW 同时结合结果模型和倾向得分模型；在条件可忽略性成立时，只要其中一个模型设定正确，估计量仍可保持一致 [Bang and Robins, 2005]。这一假设本身不能由数据完全证明，因此后文同时报告倾向得分分布和平衡性变化，用来检查估计是否过度依赖缺少共同支撑的样本。

3 数据与数据检查

本文使用 CFPS 2022 数据 [Xie and Lu, 2015, Institute of Social Science Survey, Peking University, 2022]。原始数据包含 9,806 个观测值。为了使收入变量和劳动市场状态具有可比性，样本限定为 18–64 岁成年人，并要求工资收入和核心控制变量非缺失。表 1 展示样本筛选过程。

表 1: 样本构造过程

步骤	样本量	规则
CFPS 2022 原始数据	9,806	
保留 18–64 岁成年人	7,975	年龄限制
要求工资变量非缺失	4,718	因变量可得
要求核心变量完整	4,699	最终分析样本

主要因变量为 $\ln(\text{wage} + 1)$ 。连续教育变量为受教育年限；AIPW 估计中的处理变量为是否完成大专及以上教育。表 2 显示，工资变量缺失是样本减少的主要来源，而多数协变量缺失比例较低。样本工资分布右尾较长，99 分位数为 300,000 元，因此后文加入工资缩尾口径作为稳健性检验。

表 2: 原始数据缺失情况检查

变量	缺失样本量	缺失比例
wage	4,934	50.32
educ	1	0.01
age__	0	0.00
gen	0	0.00
mar	261	2.66
rural	97	0.99
urban	79	0.81
health	139	1.42
inter	350	3.57
dw	408	4.16
asset	926	9.44

表 3: 描述性统计

变量	样本量	均值	标准差	最小值	中位数	最大值
年度工资收入	4,699	60594.132	68985.459	0.000	48000.000	1800000.000
ln(工资 + 1)	4,699	10.489	1.567	0.000	10.779	14.403
受教育年限	4,699	11.006	4.376	0.000	12.000	22.000
大专及以上	4,699	0.347	0.476	0.000	0.000	1.000
出生年份	4,699	1981.133	10.921	1958.000	1982.000	2004.000
年龄	4,699	40.867	10.921	18.000	40.000	64.000
男性	4,699	0.575	0.494	0.000	1.000	1.000
农业户口	4,699	0.795	0.404	0.000	1.000	1.000
城镇居住	4,667	0.637	0.481	0.000	1.000	1.000
是否上网	4,685	0.874	0.332	0.000	1.000	1.000
自评健康	4,673	3.215	1.045	1.000	3.000	5.000

表 4: 教育水平分布

教育类别	样本量	占比 (%)
文盲	243	5.17
小学	589	12.53
初中	1,463	31.13
高中	774	16.47
大专	702	14.94
本科	824	17.54
硕士	91	1.94
博士	13	0.28




图 1: 分析样本的教育构成




图 2: 不同教育水平的平均对数工资

4 实证策略

4.1 OLS 基准模型

基准模型为：

$$\ln(\text{wage}_i + 1) = \alpha + \beta E_i + \gamma X_i + \mu_p + \varepsilon_i, \quad (1)$$

其中 E_i 表示受教育年限或大专及以上学历教育， X_i 为控制变量， μ_p 为省份固定效应。所有回归均使用稳健标准误。OLS 回归用于给出最直观的教育收入梯度，后文不把该系数直接解释为严格因果效应。

4.2 双重稳健处理效应估计

本文的核心估计量是大专及以上学历教育的平均处理效应：

$$ATE = E[Y_i(1) - Y_i(0)]. \quad (2)$$

AIPW 个体得分分为：

$$\hat{\tau}_i = \hat{m}_1(X_i) - \hat{m}_0(X_i) + \frac{D_i(Y_i - \hat{m}_1(X_i))}{\hat{e}(X_i)} - \frac{(1 - D_i)(Y_i - \hat{m}_0(X_i))}{1 - \hat{e}(X_i)}, \quad (3)$$

其中 D_i 表示是否完成大专及以上学历教育， $\hat{e}(X_i)$ 为倾向得分， $\hat{m}_d(X_i)$ 为处理状态 d 下的预测收入。估计时使用五折交叉拟合，避免同一批样本同时训练和评估辅助模型。本文同时报告线性模型和梯度提升模型。首选设定控制年龄、性别、户口、城乡、婚姻、医保和省份；扩展设定进一步加入健康、家庭规模、社会地位、是否上网和就业状态。

4.3 扩招工具变量诊断

1999 年中国高等教育扩招提供了一个可能的政策冲击。本文用出生年份减 1981 作为 running variable，因为 1981 年出生队列在 1999 年大约 18 岁。若该设计有效，1981 年及以后出生的队列应在教育水平上出现局部跳跃。本文在多个对称出生队列窗口中报告第一阶段和 IV 估计，用第一阶段强度判断该识别思路是否可用。

5 实证结果

5.1 OLS 基准结果

表 5 给出了 OLS 基准结果。基础设定中，受教育年限系数为 0.088；加入更多控制变量后为 0.083。若把教育变量换成“大专及以上学历”，基础设定系数为 0.738，扩展设定为 0.694。

不同口径下系数都为正，说明教育收入梯度并不是由某一个具体模型设定驱动的。

表 5: OLS 基准估计

模型	系数	稳健标准误	样本量	R^2
年限: 基础控制	0.0882***	(0.0062)	4,699	0.158
年限: 扩展控制	0.0825***	(0.0065)	4,637	0.163
大专: 基础控制	0.7381***	(0.0502)	4,699	0.154
大专: 扩展控制	0.6935***	(0.0509)	4,637	0.162
工资缩尾	0.7291***	(0.0499)	4,699	0.152
正工资样本	0.6420***	(0.0300)	4,638	0.285

注：括号内为稳健标准误。基础控制变量包括年龄、年龄平方、性别、婚姻、农业户口、医保和省份固定效应；扩展控制变量进一步加入城乡、健康、家庭规模、是否上网和主观社会地位。 $*p < 0.10$, $**p < 0.05$, $***p < 0.01$ 。




图 3: 不同模型中的教育收入系数

5.2 双重稳健估计

表 6 报告 AIPW 结果。首选的 Core plus + GBM 估计为 0.710，标准误为 0.056。六组设定的估计范围为 0.669–0.773。与 OLS 中“大专及以上”的系数相比，AIPW 估计略小，但仍保持较大的正值，说明在平衡可观测差异后，高等教育收入优势仍然明显。

表 6: 大专及以上学历教育的 AIPW 估计

协变量	学习器	ATE	标准误	95% CI	样本量	AUC
Core	Linear	0.7726***	(0.0551)	[0.6647, 0.8806]	4,699	0.814
Core	GBM	0.7206***	(0.0553)	[0.6123, 0.8289]	4,699	0.822
Core plus	Linear	0.7611***	(0.0583)	[0.6467, 0.8755]	4,699	0.816
Core plus	GBM	0.7103***	(0.0556)	[0.6014, 0.8193]	4,699	0.827
Extended	Linear	0.7088***	(0.0544)	[0.6022, 0.8154]	4,699	0.829
Extended	GBM	0.6690***	(0.0495)	[0.5720, 0.7660]	4,699	0.844

注：因变量为 $\ln(\text{wage} + 1)$ 。ATE 表示完成大专及以上学历教育的平均处理效应。Linear 使用逻辑回归/Ridge 结果模型；GBM 使用梯度提升模型。首选设定为 Core plus + GBM。

AIPW 的可信度取决于共同支撑和平衡性。图 4 显示处理组和对照组在较宽的倾向得分区间内存在重叠，但两端仍有少量样本，提示估计并非完全没有外推风险。表 7 和图 5 显示，加权后核心协变量的标准化差异绝对值均降至 0.10 以下，样本可比性明显改善。




图 4: 倾向得分共同支撑

表 7: 加权前后的协变量平衡性

协变量	原始 SMD	加权 SMD
age__	-0.937	-0.072
gen	-0.214	0.033
rural	-0.525	-0.024
urban	0.642	0.033
mar	-0.286	-0.023
medsure_dum	0.079	-0.001




图 5: 加权前后的标准化均值差异

5.3 弱工具变量诊断

图 6 展示 1981 年 cutoff 附近出生队列的大专及以上比例和平均教育年限。表 8 显示, 在 ± 5 到 ± 15 年的较窄窗口中, 第一阶段 F 统计量远低于常用弱工具变量阈值。 ± 20 年窗口的第一阶段较强, 但窗口过宽, 已经很难解释为局部断点。因此, 本文不把扩招 IV 作为主要因果证据, 而只把它作为一个经过检验的政策识别尝试。




图 6: 高等教育扩招 cutoff 附近的出生队列模式

表 8: 高等教育扩招 IV 诊断

窗口	样本量	第一阶段	F 统计量	IV 估计	标准误
+/-5	1,280	-0.0743	0.03	0.5195	(3.2703)
+/-7	1,844	0.1961	0.29	0.4589	(0.9572)
+/-9	2,462	-0.0481	0.02	0.2091	(2.4996)
+/-12	3,277	0.1269	0.21	-0.7816	(2.0357)
+/-15	3,933	0.3977	2.54	-0.1531	(0.2721)
+/-20	4,596	1.2985	33.22	0.0414	(0.0633)

注：工具变量为是否出生于 1981 年及以后，并控制线性 running variable、交互项和省份固定效应。较窄窗口中的第一阶段较弱，因此 IV 结果不应被解释为主要因果证据。

5.4 异质性

表 9 和图 7 显示，女性样本中的教育系数高于男性，非农业户口样本中的教育系数高于农业户口样本。这与中国教育回报存在性别、户口、部门和地区差异的既有文献相一致 [Ma and Iwasaki, 2021, Li et al., 2025]。

表 9: 不同子样本中的教育系数

子样本	教育系数	稳健标准误	样本量	R^2
女性	0.1104***	(0.0094)	1,996	0.155
男性	0.0668***	(0.0069)	2,703	0.145
非农业户口	0.1482***	(0.0201)	962	0.144
农业户口	0.0771***	(0.0066)	3,737	0.128




图 7: 性别与户口子样本中的教育收入系数

6 讨论

从结果看，本文的主要证据并不是单一 OLS 系数，而是一组相互校验的结果。样本审计说明了工资变量缺失和极端值处理方式；OLS 给出了基础教育收入梯度；AIPW 在平衡可观测差异后仍得到较大的大专及以上学历教育效应；扩招诊断则说明，当前横截面数据不足以支撑强 IV 结论。这样的结果比单纯报告“教育系数显著为正”更完整，也更能说明识别边界。

本文仍有局限。AIPW 依赖可观测变量调整，而当前数据文件缺少能力、父母教育、童年家庭资源和学校质量等重要变量。因此，首选估计应理解为选择性可观测条件下的处理效应，而不是完全等同于随机实验或强工具变量估计。扩招 IV 的弱第一阶段也说明，仅凭当前横截面数据不宜做过强的政策因果结论。

7 结论

基于 CFPS 2022, 本文发现教育与中国成年人收入之间存在显著正向关系。传统明瑟模型中, 受教育年限每增加一年, 工资收入约高 8.8%。在 AIPW 框架下, 完成大专及以上学历教育对应约 0.71 个对数点的工资收入优势; 这一结果在不同协变量口径和学习器下保持稳定, 且加权后协变量平衡明显改善。更谨慎地说, 本文证明的是: 在当前数据能够观察到的个人和家庭特征得到控制后, 高等教育仍然与更高收入紧密相关。若要进一步识别严格因果效应, 还需要更强的政策冲击、面板追踪或更完整的家庭背景变量。

参考文献

- M. Niaz Asadullah and Saizi Xiao. The changing pattern of wage returns to education in post-reform china. *Structural Change and Economic Dynamics*, 53:137–148, 2020. doi: 10.1016/j.strueco.2020.01.010.
- Heejung Bang and James M. Robins. Doubly robust estimation in missing data and causal inference models. *Biometrics*, 61(4):962–973, 2005. doi: 10.1111/j.1541-0420.2005.00377.x.
- Gary S. Becker. *Human Capital: A Theoretical and Empirical Analysis, with Special Reference to Education*. National Bureau of Economic Research, New York, 1964. URL <https://www.nber.org/books-and-chapters/human-capital-theoretical-and-empirical-analysis-special-reference-education-first-edition>.
- David Card. The causal effect of education on earnings. In Orley C. Ashenfelter and David Card, editors, *Handbook of Labor Economics*, volume 3A, pages 1801–1863. Elsevier, 1999. doi: 10.1016/S1573-4463(99)03011-4.
- James J. Heckman, Lance J. Lochner, and Petra E. Todd. Earnings functions and rates of return. *Journal of Human Capital*, 2(1):1–31, 2008. doi: 10.1086/587037.
- Keisuke Hirano, Guido W. Imbens, and Geert Ridder. Efficient estimation of average treatment effects using the estimated propensity score. *Econometrica*, 71(4):1161–1189, 2003. doi: 10.1111/1468-0262.00442.
- Bin Huang, Massimiliano Tani, Yi Wei, and Yu Zhu. Returns to education in china: Evidence from the great higher education expansion. *China Economic Review*, 74:101804, 2022. doi: 10.1016/j.chieco.2022.101804.

- Guido W. Imbens and Thomas Lemieux. Regression discontinuity designs: A guide to practice. *Journal of Econometrics*, 142(2):615–635, 2008. doi: 10.1016/j.jeconom.2007.05.001.
- Institute of Social Science Survey, Peking University. China family panel studies 2022. Survey data, 2022. URL <https://www.isss.pku.edu.cn/cfps/>.
- David S. Lee and Thomas Lemieux. Regression discontinuity designs in economics. *Journal of Economic Literature*, 48(2):281–355, 2010. doi: 10.1257/jel.48.2.281.
- Mingming Li, Xinyun Hu, and Keyan Jin. The return on education and the gender wage gap in china: A sector perspective. *SAGE Open*, 2025. doi: 10.1177/21582440251327015.
- Xinxin Ma and Ichiro Iwasaki. Return to schooling in china: A large meta-analysis. *Education Economics*, 29(4):379–410, 2021. doi: 10.1080/09645292.2021.1900791.
- Jacob Mincer. *Schooling, Experience, and Earnings*. National Bureau of Economic Research, New York, 1974. URL <https://www.nber.org/books-and-chapters/schooling-experience-and-earnings>.
- Yu Xie and Ping Lu. The sampling design of the china family panel studies (cfps). *Chinese Journal of Sociology*, 1(4):471–484, 2015. doi: 10.1177/2057150X15614535.
- Junsen Zhang, Yaohui Zhao, Albert Park, and Xiaoqing Song. Economic returns to schooling in urban china, 1988 to 2001. *Journal of Comparative Economics*, 33(4):730–752, 2005. doi: 10.1016/j.jce.2005.05.008.